第十届全国大学生生物医学工程创新设计竞赛

预赛作品报告

深度学习框架下基于图像到图像的扩散模型稀疏发射肌骨超声图像重建研究

作品 ID 号：7113

参赛学生类型：本科生

参加赛道：医工 AI 赋能

组别：自选项目组

2025 年 6 月

内容完整性自查表

说明：

1. 命题组参赛作品请根据命题文件规定或要求的指标填写；
2. 自选组参赛作品请根据实际参赛作品完成情况填写。

完整性类别	任务或技术指标名称	完成效果	呈现方式（报告中的章节、页码，或者测试报告，或实物、视频等）
	1.评价模型指标的选择	良好	第 7 页
	2.通过 PSNR 指标横向对比重建图像质量，验证模型效果	良好	第 7 页
	3.通过 SSIM 指标横向对比重建图像质量验证模型效果	良好	第 7 页
	4.通过 LPIPS 指标横向对比重建图像质量验证该模型效果	良好	第 8 页
	5.Palette 图像到图像扩散模型的训练结果	良好	第 9 页
	6.各种图像去噪方法的对比	良好	第 9 页
其他			

摘　　要

超声计算机断层扫描（USCT）是一种结合传统超声成像与计算机断层扫描原理的新型医学成像技术，在肌骨疾病诊断中起到至关重要的作用。USCT 利用环绕目标的环形换能器阵列，捕捉反射和透射信号，来构建三维图像。市售超声计算机断层扫描仪一般采用 512 个环形排列的探头，依次进行发射和接收，虽然重建效果较好，但因数据采集时间长，数据吞吐量大，所以速度缓慢，需要患者等待一定时间。稀疏发射成像技术选取间隔相等的若干个（8/16/32 个)探头发射并重建，通过减少发射和接收次数可以减少数据采集时间并降低数据吞吐量，但是会造成重建图像噪声放大，出现伪影，细节模糊不清等问题，并不能直接用于临床诊断。因此，我们希望能够训练一个针对肌骨 USCT 图像去噪的模型，做到输入为稀疏发射重建图像，输出为质量提高的稀疏发射重建图像，进而对临床诊断起到参考作用。为此，我们应用 Palette 图像到图像扩散模型进行图像重建。Palette 图像到图像扩散模型的核心思想源于扩散模型（Diffusion Model）框架。模型通过逐步向输入图像中添加高斯噪声，最终使得整个图像完全变成一个符合高斯分布的噪声图像，再使用改进的 U-Net 神经网络作为生成器学习逆向去噪过程，最终从纯噪声中恢复出高质量的数据。模型去噪后图像经过小波变换去除高斯噪声和椒盐噪声后，得到最终输出。最终输出图像与标准图像进行 PSNR，SSIM，LPIPS 三个指标的计算，直接验证图像去噪效果，并通过对比试验横向验证 Palette 图像到图像扩散模型的效果。实验指标显示，Palette 图像到图像扩散模型在 PSNR 和 LPIPS 两个指标上都优于横向对比的所有模型，SSIM 指标也相对较好。实验结果表明，Palette 模型对稀疏发射图像重建有提高作用。

关键词：超声计算断层扫描，扩散模型，稀疏发射重建技术，深度学习

目录

摘　　要 3
1　作品概述 1
1.1 背景及意义 1
1.2 研究基础 1
1.3 需求分析 1
1.4 研究目标 2
2　作品方案设计及实现 3
2.1 作品实现的技术路线概述 3
2.2 技术方案对比 4
2.3 作品方案设计及实现过程 4
3 作品测试方案及测试结果 8
3.1 测试方案 8
3.2 技术、功能指标及测试结果 10
3.3 技术可行性分析及创新说明 10
4 总结 12
4.1 作品展示 12
4.2 展望 13

1 作品概述

1.1 背景及意义

超声计算机断层扫描（USCT）是一种通过分析人体组织声学特性实现成像的技术，在人体肌肉骨骼成像中具有重要价值。其无辐射特性使其成为儿童骨骼发育异常的优选检查，同时能评估类风湿关节炎的滑膜炎症、骨侵蚀程度，在临床上极具潜力。许多深度学习算法被用于 USCT 技术，如 D2GAN 通过跨域信息融合与多尺度特征学习，有效平衡了 PET 成像的辐射安全与图像质量，为临床低剂量 PET 技术的普及提供了可行的深度学习方案[13]。有研究表明，级联扩散模型可在类条件 ImageNet 生成基准上生成高保真图像[14]。传统的 USCT 图像重建技术采集时间长，数据吞吐量大，导致患者等待时间较长，容易错过病情的最佳处理时机。稀疏发射技术可以减少数据采集时间，但是会造成图像质量下降，时空分辨率下降。我们通过对稀疏发射重建图像的再处理，极大地提高了图像的处理速度与重建效果，可用于快速准确地诊断运动损伤（如肌肉拉伤、韧带扭伤），这在运动医学等一类需要快速医疗介入的应用中极具潜力，同时，在急诊等场景下可以有效减少患者等待时间，为急症病情的诊疗抢得宝贵的时间。

1.2 研究基础

深度学习（DL）方法已在医学成像领域成功用于从含噪图像中重建高质量图像，可以在不降低图像重建效果的前提下加快图像处理的速度。2015 年，Sohl - Dickstein 等人首次将扩散过程引入深度生成模型的框架，奠定了扩散模型（Diffusion Model）的理论基础，2018 年，扩散模型被正式提出，通过学习数据分布的逆过程，实现了更加稳定、多样化的样本生成。近年来，扩散模型及其各种变体在医学图像处理领域中逐渐展露前景，我们希望结合扩散模型提高从稀疏发射数据中获取的 USCT 图像质量，进而为医生的快速判断提供有效依据。

1.3 需求分析

中国 50 岁以上人群约 8,900 万 患骨质疏松症（《中国骨质疏松症流行病学调查》2023 年数据），女性占比约 70%。每年因骨质疏松导致骨折约 270 万例，其中髋部骨折发病率以每年 1.5%的速度增长。每年膝关节置换手术量超 70 万台，年增长率约 15%。其中骨关节炎在早期被发现时可通过药物、减重和物理治疗延缓软骨磨损，避免后期关节置换手术；骨质疏松早期可以通过及时补钙、抗骨松药物减少骨折风险，因此，骨科疾病的早期预防检查显得尤为重要。在急症等场

景下，患者的平均候诊时间长达 5 小时，而脊髓损伤等骨科疾病的最佳处理时间窗仅为 4 到 8 小时，关节脱位等更是只有 2 小时，快速的病情检测结果十分必要。

1.4 研究目标

USCT 中环形换能器中的单个元件在每次传输时发射球面波，而所有元件同时接收超声信号。每个元件依次发射，重复此步骤，最终从每个发射-接收对获取完整的原始数据集。通过组合这些低分辨率图像，最终在发射和接收事件中动态聚焦生成高分辨率图像。

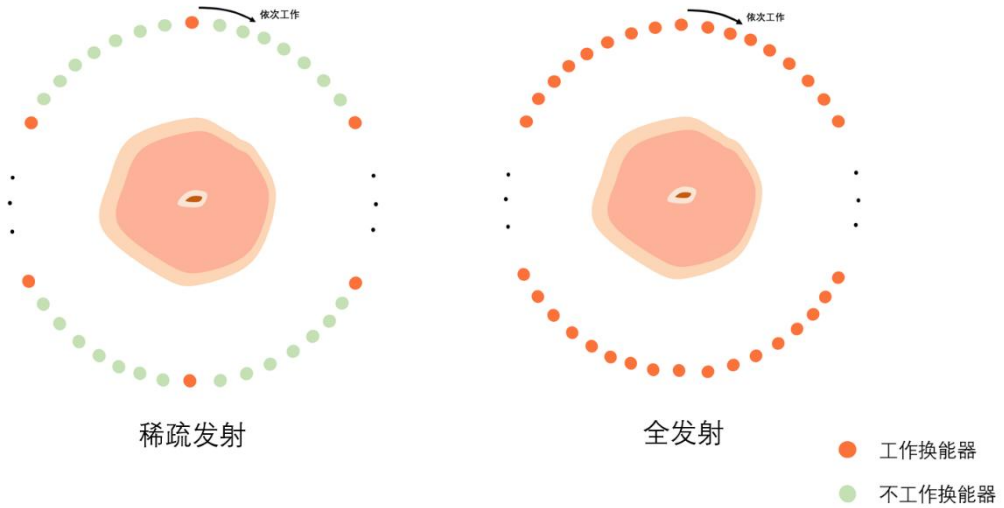

图 1 稀疏发射与全发射示意图

然而，合成孔径方法需要耗时的扫描过程来从多个传输方向获取全采样数据。超声信号在触发信号后按顺序发射和接收。为避免潜在干扰，两次相邻超声传输的时间间隔为 2 ms。数据采集时间等于传输次数乘以 2 ms，而图像重建时间与传输次数大致成正比。稀疏传输策略可减轻数据采集的复杂性，但会导致图像重建效果的下降，为解决上述问题，我们提出一种从稀疏传输数据重建 USCT 图像的深度学习方法。

我们的目标是研发一种针对稀疏发射重建图像的再生成，提供一种方法在保留稀疏发射数据重建图像速度快的优点的条件下生成更加高质量，低噪声的新图像便于医护人员对骨科疾病进行早期诊断，并及早进行干预。

2 作品方案设计及实现

2.1 作品实现的技术路线概述

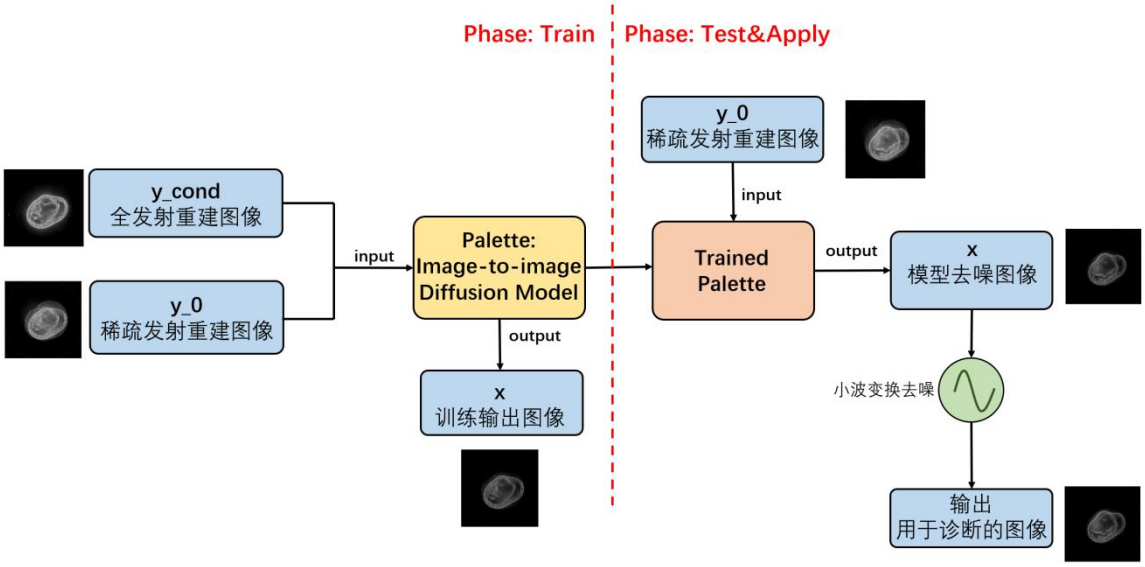

图 2 模型的训练，检测和应用流程图

Palette 图像到图像扩散模型[1]是一种基于 Diffusion 模型的通用图像转换模型，可用于图像着色，修复，补全和恢复等多种任务。我们应用了 Palette 模型中的 Colorization 功能，以稀疏发射重建图像为输入，全发射重建图像为条件输入训练模型。Diffusion 的核心步骤包括前向扩散和反向去噪。前向扩散过程中通过对输入图像不断加高斯噪声，最终得到一个完全的噪声图像；反向去噪过程中用嵌入注意力机制和残差网络的 U-Net 来对噪声进行预测。通过计算损失函数并更新超参数来使噪声预测值更接近真实噪声值。将训练好的模型进行测试，仅输入稀疏发射重建的图像，得到经过模型去噪的输出图像。将模型输出图像经过小波变换处理后，输出为去噪图像。去噪图像与全发射重建图像进行指标的计算，并将结果与稀疏发射重建图像与全发射重建图像之间的指标进行对比，以此验证去噪效果。模型训练检测和应用整体步骤如图 2。

2.2 技术方案对比

我们选取了 NLM,BM3D,CycleGAN 几个方法与我们的模型进行对比，采用 PSNR,SSIM,LPIPS 三个参数指标对模型重建效果进行评估，下面将简单地介绍一下参与对比的几个模型。

1. 非局部均值（NLM）方法[2]

2005 年由 Antoni Buades 等人提出，主要用于图像去噪。非局部均值（NLM）方法利用自然图像的自相似性特性对每个像素进行去噪，在去噪的同时最大限度地保留了图像的细节，同时，因为去噪时运用了全图信息，使得去噪后图像更自然，很少产生块效应。

2. 块匹配 3D 滤波（BM3D）方法[3]

块匹配 3D 滤波方法将相似图像块分组为三维结构，并在 3D 变换域中进行协同滤波，从而同时利用图像的空间自相似性和变换域稀疏性，实现远超传统方法的去噪效果。去噪过程分为两个阶段，第一阶段采用硬阈值滤波，生成初步去噪结果 $\hat{y}_1$ 为第二阶段提供准确的块匹配参考，第二阶段基于 $\hat{y}_1$ 改进块匹配精度，应用维纳滤波生成最终去噪图像。

3. 循环生成对抗网络（CycleGAN）方法[5]

2017 年，由朱俊彦等人提出一种生成式对抗网络（GAN）的变体 CycleGAN，其提出的背景是为了解决图像到图像转换任务中对成对图像数据的依赖问题。CycleGAN 通过双向循环一致性机制，实现了非配对数据下的跨域图像转换，其架构由两个生成器和两个判别器组成，形成“双 GAN”循环系统。优势在于仅需两个域的独立数据，大幅降低数据收集成本且具有较强的模型泛化能力。

2.3 作品方案设计及实现过程

扩散模型自 2018 年正式问世以来，就在图像生成方面表现出强大的功能和真实性，被应用在诸多领域。但是最初的扩散模型属于无监督学习，输出仅与输入相关。但 Palette 图像到图像扩散模型中引入了条件图像。在噪声推理中，将条件图像作为先验条件进行噪声的预测，可以使输出在保留原有结构的基础上趋向于条件图像。基于上述优化，我们将稀疏发射重建图像作为输入，全发射重建图像作为条件图像训练模型。在训练过程中，正向过程不断加入高斯噪声，使得图像

数据逐渐被覆盖，直到最终图像完全变为一个符合高斯分布的噪声（图 3）。

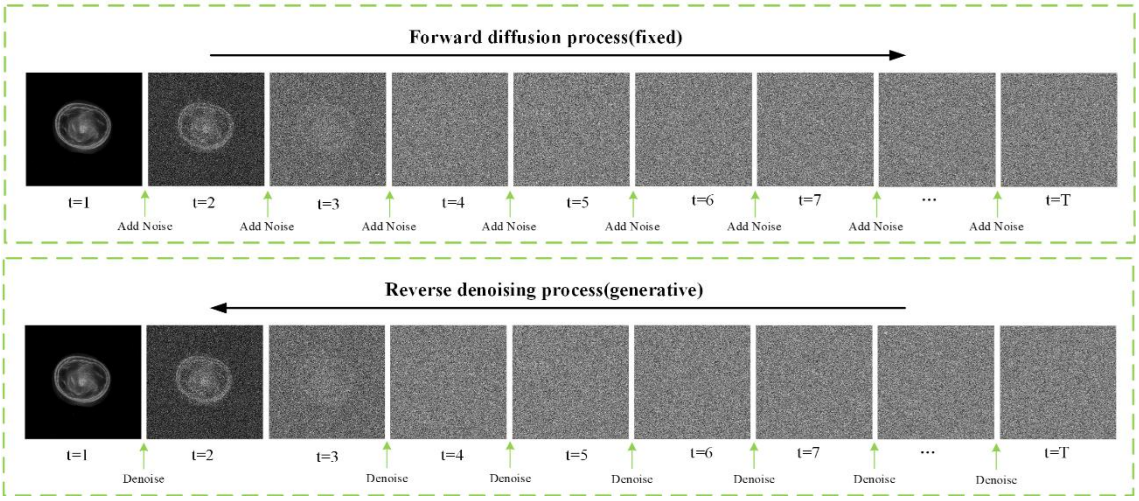

图 3 前向扩散与反向去噪示意图

因为在前向扩散过程中，某一时间步的结果仅由上一时间步决定，故可用马尔科夫链来表示噪声，根据高斯噪声特点，公式可化为：

$$q(x_t \mid x_{t-1}) = \mathrm{N}(x_t; \sqrt{1-\beta} x_{t-1}, \beta_t \mathrm{I})$$

反向去噪过程中我们用一个改进的 U-Net 来生成图像，学习逐步去噪的过程，即从 x_t 预测 x_{t-1}，公式如下：

$$p_\theta(x_{t-1} \mid x_t) = \mathrm{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

本文应用的生成器以 U-Net[6]的编码器-解码器结构为基础架构，通过跳跃连接实现特征融合。在编码器部分，输入 512×512×2 的灰度图，下采样由平均池化和残差块组成。在每个下采样步骤中，特征通道的数量翻倍，特征的分辨率减半。在中间层中，对特征图应用残差块-自注意力-残差块对特征图进行处理，实现残差块提取局部特征，自注意力层捕捉长距离依赖，残差块整合局部与全局特征。上采样包括转置卷积，跳跃连接和残差块[12]。跳跃连接增加保留的细节并防止训练过程中梯度爆炸。上采样操作将图像对称扩展到相应编码器层的大小。

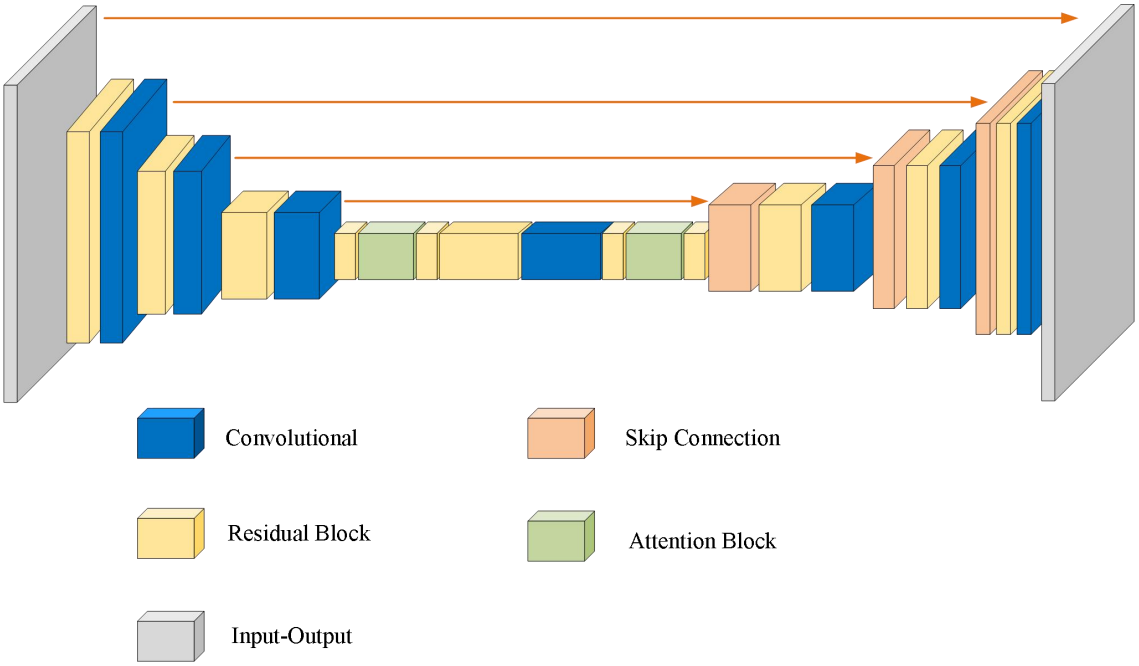

图 4 Palette 生成器 U-Net 网络结构示意图

Palette 图像到图像扩散模型应用 QKV 注意力机制。考虑到 QKV 注意力机制在捕捉图像中的长距离语义关联中表现出色，预测其在辨别不同组织纹理特性并保留纹理中的表现会比其他注意力机制出色。同时，将其应用于残差块之间可以起到动态调整噪声预测权重的作用。

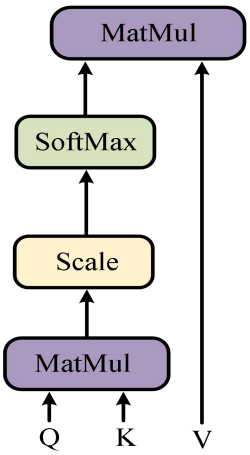

图 5 QKV 注意力机制工作流程

QKV 注意力模块通过 Query、Key、Value 三个矩阵的交互来计算全局注意力权重，其值可由如下公式求得：

$$Attention(Q,K,V) = soft\max(\frac{QK^T}{\sqrt{d_k}})V$$

相比于其他注意力机制，QKV 注意力在处理我们的目标时可以自适应捕获任意位置的依赖关系，可以更加灵活地实现动态全局建模，精准捕捉关键语义关联，大大提高了生成图像的整体质量。

在 U-Net 的学习过程中，损失函数采用了两项内容损失项。像素级损失 L_1 用于衡量预测图像与目标图像中像素强度的距离，有助于提升图像的平滑度，感知损失 L_{VGG} 则整合了高级感知信息与图像语义差异，更适应于人体视觉习惯。最终的联合生成损失定义为三项的加权和，公式如下：

$$LG = L_a{}^d{}_v + \lambda_1 L_1 + \lambda_2 L_{VGG}$$

其中，$L_a{}^d{}_v$，L_1 和 L_{VGG} 分别表示条件对抗损失、像素级损失和感知损失。λ_1 和 λ_2 为加权参数，用于平衡三项损失的贡献。

最后，我们对于生成的输出图像进行了噪声评估，发现其含有较多的斑点噪声，我们采取了小波变换对该斑点噪声进行处理，发现小波变换在最终图像的去噪方面具有相当优秀的表现，参数 PSNR，SSIM 的数值均有所变大，代表新的模型在像素级还原度更好，提高了输出图像的重建质量。

3 作品测试方案及测试结果

3.1 测试方案

不同人对图像质量的主观感受存在差异（如对色彩、模糊的敏感度不同），且疲劳、环境光线等因素会影响判断，引入指标可以实现标准化的定量对比，避免人主观判断的局限性。而在在图像处理和计算机视觉领域，PSNR、SSIM 和 LPIPS 是常用的评价指标，下面将详细介绍每个指标的功能，适用范围和计算公式。

1.训练模型 PSNR[8]参数测试

PSNR 参数基于均方误差（MSE），通过对信噪比进行对数转换，将大的动态范围压缩到较小的尺度，更符合人类对变化的感知，适用于简单降噪、压缩任务的快速评估，PSNR 指标较大说明两个图像之间的像素级失真较小。PSNR 指标可以使用公式（1）和公式（2）计算：

$$MSE = \frac{1}{MN}\sum_{i=1}^{M}\sum_{j=1}^{N}[I_1(i,j) - I_2(i,j)]^2 \quad \text{.....(1)}$$

$$PSNR = 10 \cdot \log_{10}(\frac{MAX^2}{MSE}) \quad \text{.....(2)}$$

2.训练模型 SSIM[9]参数测试

SSIM 基于人类视觉系统（HVS）的感知模型，是一种用于衡量两幅图像在亮度、对比度和结构上相似度的指标。与 PSNR 不同，SSIM 更加贴近人类视觉系统的感知，能够更准确地反映图像质量，适用于图像复原、质量评估，SSIM 指标较大说明两个图像之间的结构与视觉相似度较高。SSIM 参数可以用公式（3）,（4）,（5）,（6）计算：

$$\mathrm{l}(\mathrm{x},\mathrm{y})=\frac{2\mu_{\mathrm{x}}\mu_{\mathrm{y}}+C_1}{\mu_x^2+\mu_y^2+C_1} \quad (3)$$

$$c(x,y)=\frac{2\sigma_x\sigma_y+C_2}{\sigma_x^2+\sigma_y^2+C_2} \quad (4)$$

$$s(x,y)=\frac{\sigma_{xy}+C_3}{\sigma_x\sigma_y+C_3} \quad (5)$$

$$SSIM(x,y)=l(x,y)\cdot c(x,y)\cdot s(x,y) \quad (6)$$

3.训练模型 LPIPS[10]参数测试

LPIPS 是一种基于深度学习的图像相似度评估指标。与传统的基于误差的评估方法不同，LPIPS 通过比较两幅图像的局部感知特征来评估它们的相似度。这些特征是通过在大量的图像对上训练一个深度卷积神经网络得到的，网络学习将图像内容映射到一个低维空间，在这个空间中，人类感知上相似的图像具有较小的距离，LPIPS 指标越小说明两个图像之间的感知语义差异越小。

LPIPS 的计算公式不是简单的数学公式，而是通过深度神经网络来实现的。通常，LPIPS 模型使用两幅图像作为输入，然后输出它们之间的感知相似性分数.具体的距离计算可由公式(7)[10]：

$$\mathrm{d}(x,x_0)=\sum_l\frac{1}{H_lW_l}\sum_{h,w}\left\|w_l\otimes(\hat{y}_{hw}^l-\hat{y}_{0hw}^l)\right\|_2^2 \quad (7)$$

3.2 技术、功能指标及测试结果

各个模型测试结果及其参数指标：

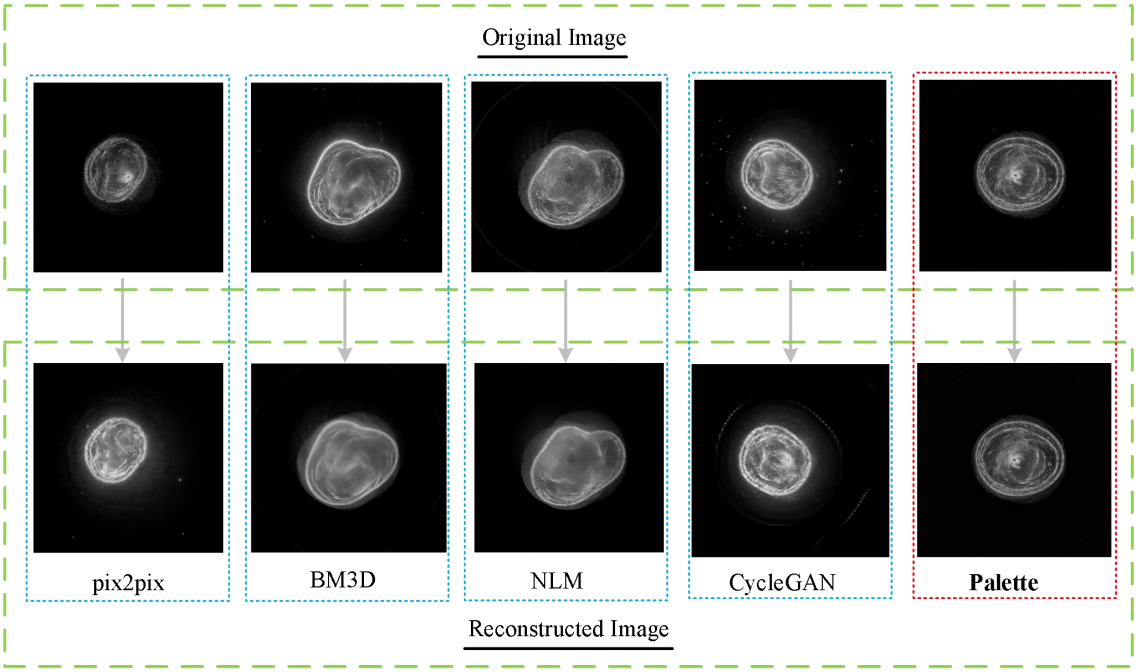

图 6 模型效果

如图 6 所示，我们将各个模型处理前后的图片效果直观展现出来。此外，为了科学严谨地评判每个模型的重建效果，我们对每一个模型的输出图像与标准图像之间的相似度都采用 PSNR，SSIM，LPIPS 三个指标来进行衡量，具体指标表现如下表 1 所示。

	PSNR 参数测试	PSNR 参数变化	SSIM 参数测试	SSIM 参数变化	LPIPS 参数测试	LPIPS 参数变化
输入与标准	21.7654	\	0.6842	\	0.2963	\
CycleGan	27.7510	↑5.9856	0.8440	↑0.1598	0.2940	↓0.0023
NLM	26.3791	↑4.6137	**0.8017**	**↑0.1175**	0.1380	↓0.1583
BM3D	21.6471	↓0.1183	0.7002	↑0.0160	0.2796	↓0.0194
Palette	**33.2241**	**↑11.4587**	0.7380	↑0.0538	**0.0273**	**↓0.1625**

表 1 各模型与标准图像对比所得参数测试结果

3.3 技术可行性分析及创新说明

Palette 图像到图像重建模型于 2022 年问世，但鲜少应用于生物医学图像处理，从未应用于肌骨图像 USCT 稀疏发射重建。目前我们已经运用优化后的 Palette 图像到图像扩散模型成功处理出了数据集中所有肌骨稀疏发射重建图像。我们的训练是在 RTX 3090 GPU 上进行，时间约为一天。在人人都可云端租用显卡的今天，

即使在医疗资源较为贫乏的地区，训练一个能对特定组织或器官稀疏发射图像有效重建的模型并非难事。用该模型进行测试，输出图像展现出良好的可分辨性和匹配相似性。该稀疏发射重建方法速度快，重建质量高，且成本低廉，在医学图像处理领域具有较强竞争力。同时，所需要的“原材料”稀疏发射重建图像易快速获取，且方法简单，有望进行临床与商业化推广。

4 总结

4.1 作品展示

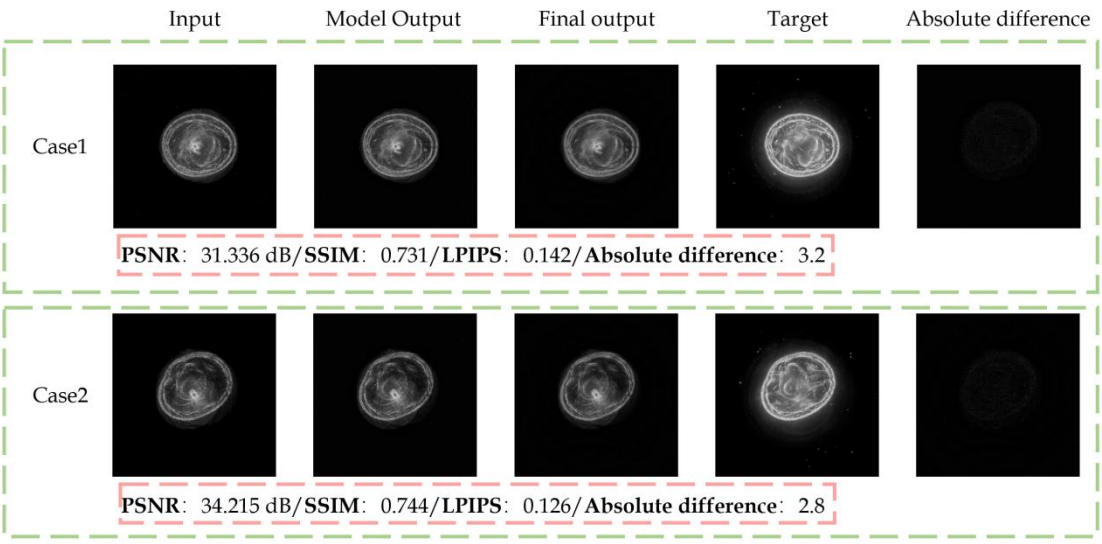

图 7

在图 7 中，我们直观地用两个例子显示了经由 Palette 图像到图像扩散模型处理稀疏发射重建图像得到的输出，以及经过小波变换去除斑点噪声之后的最终输出，并与标准图进行了对比。

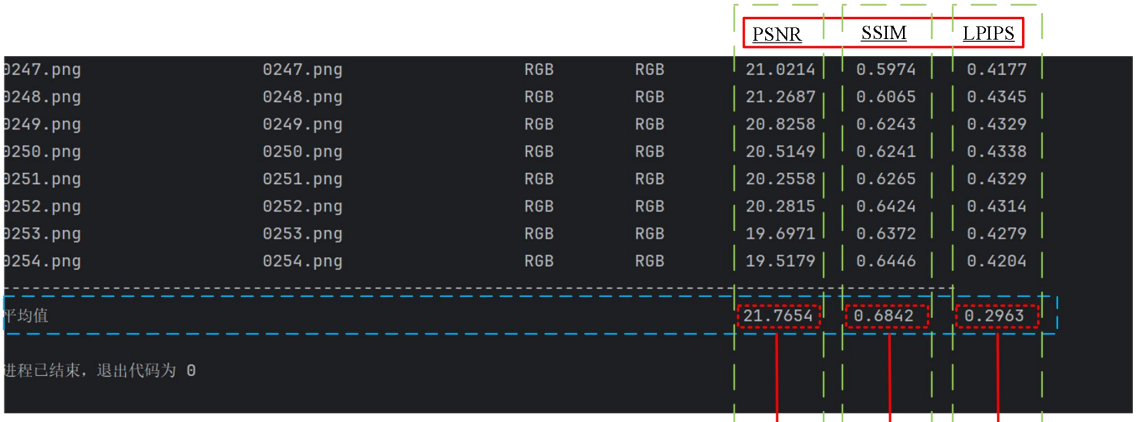

				PSNR	SSIM	LPIPS
0247.png	0247.png	RGB	RGB	21.0214	0.5974	0.4177
0248.png	0248.png	RGB	RGB	21.2687	0.6065	0.4345
0249.png	0249.png	RGB	RGB	20.8258	0.6243	0.4329
0250.png	0250.png	RGB	RGB	20.5149	0.6241	0.4338
0251.png	0251.png	RGB	RGB	20.2558	0.6265	0.4329
0252.png	0252.png	RGB	RGB	20.2815	0.6424	0.4314
0253.png	0253.png	RGB	RGB	19.6971	0.6372	0.4279
0254.png	0254.png	RGB	RGB	19.5179	0.6446	0.4204
平均值				21.7654	0.6842	0.2963

进程已结束，退出代码为 0

(a)

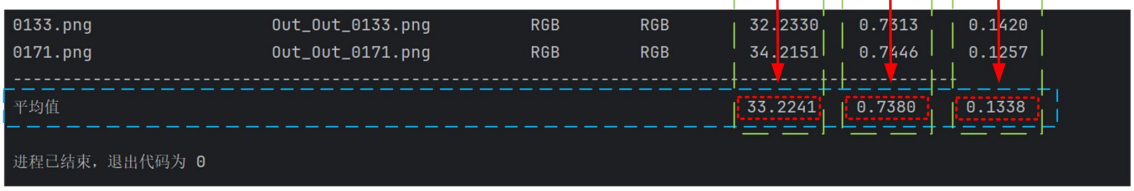

0133.png	Out_Out_0133.png	RGB	RGB	32.2330	0.7313	0.1420
0171.png	Out_Out_0171.png	RGB	RGB	34.2151	0.7446	0.1257
平均值				33.2241	0.7380	0.1338

进程已结束，退出代码为 0

(b)

图 8 (a)原始输入图像对比标准图像的参数指标 (b)经过我们训练的模型输出的重建图像对比标准图像的参数指标

我们希望通过模型处理前后参数指标的变化来客观的展现图像的重建效果，如图 8，（注：图中的参数指标都是与标准图像比对得到的），可以看到经过我们模型的处理 PSNR 和 SSIM 指标显著提升，表明我们的模型在像素级的还原上非常成功，其与标准图的结构相似度与视觉相似度均有显著提升。与此同时，图像的 LPIPS 指标显著下降，表明我们的模型生成的图像人类更难感受到其与标准图的差异，生成的重建图像在风格迁移方面更优。

4.2 展望

我们开发的优化 Palette 图像到图像扩散模型大大提高了稀疏发射超声图像的重建质量，在保留原有图像关键信息的同时，USCT 系统仅使用 8 次发射接受数据即可重建出接近 512 次发射接收数据的高质量图像[11]。在保留稀疏发射超声图像高速的优点下，保证了图像输出的质量。该技术有望集成到现有 USCT 成像系统中，在保持高图像质量的同时大幅缩短数据采集时间。但是，我们重建的图像对于原始输入细节的保留非常一般，对于低频信号的的处理也不够好，给骨科疾病的诊断带来了不小的困难，后续我们会尝试分高低频分别训练等方法尝试重建出更加高质量的图像。如果能对质量和生成速度进行优化，则有望将其应用于实时 USCT 成像。

参考文献:

[1] Saharia C, Chan W, Chang H, et al. Palette: Image-to-image diffusion models[C]//ACM SIGGRAPH 2022 conference proceedings. 2022: 1-10.

[2] Buades A, Coll B, Morel J M. A review of image denoising algorithms, with a new one[J]. Multiscale modeling & simulation, 2005, 4(2): 490-530.

[3] Dabov K, Foi A, Katkovnik V, et al. Image denoising by sparse 3-D transform-domain collaborative filtering[J]. IEEE Transactions on image processing, 2007, 16(8): 2080-2095.

[4] Isola P, Zhu J Y, Zhou T, et al. Image-to-image translation with conditional adversarial networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1125-1134.

[5] Zhu J Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2223-2232.

[6] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18. Springer international publishing, 2015: 234-241.

[7] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

[8] Tanchenko A. Visual-PSNR measure of image quality[J]. Journal of Visual Communication and Image Representation, 2014, 25(5): 874-878.

[9] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE transactions on image processing, 2004, 13(4): 600-612.

[10] Zhang R, Isola P, Efros A A, et al. The unreasonable effectiveness of deep features as a perceptual metric[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 586-595.

[11] Liu Z, Zhou X, Yang H, et al. Reconstruction of reflection ultrasound computed tomography with sparse transmissions using conditional generative adversarial network[J]. Ultrasonics, 2025, 145: 107486.

[12] Gong K, Johnson K, El Fakhri G, et al. PET image denoising based on denoising diffusion probabilistic model[J]. European Journal of Nuclear Medicine and Molecular Imaging, 2024, 51(2): 358-368.

[13] Jiang L, Cui J, Xu Y, et al. D2GAN: A Dual-Domain Generative Adversarial Network for High-Quality PET Image Reconstruction[C]//2024 International Joint Conference on Neural Networks (IJCNN). IEEE, 2024: 1-8.

[14] Ho J, Saharia C, Chan W, et al. Cascaded diffusion models for high fidelity image generation[J]. Journal of Machine Learning Research, 2022, 23(47): 1-33.